

É P I S O D E # 1

IA Coffee

Agentic AI



LLM

Token

Agent

RAG

MCP

Skills

DeepSeek

Tool Use

1h30 · 3 démos live · Q&R

AU PROGRAMME CE SOIR



Les fondations

LLM · DeepSeek · Token · Contexte · Température



Les données

RAG · Embeddings · Vector DB · Chunking



Les agents

Agent · Tools · Planning · Memory · ReAct



L'écosystème

MCP · Skills · Orchestration · Multi-agents



Demos live

RAG chatbot · Agent researcher · Build avec Claude Code



Q&R

Questions ouvertes · Retours d'expérience · Ressources

LLM — Large Language Model

Un modèle de langage entraîné sur des centaines de milliards de mots pour prédire le token suivant.

Il ne « comprend » pas — il complète. La puissance vient de l'échelle.

Paramètres

7B → 1 000B+

Poids ajustés à l'entraînement. Plus = plus capable, mais plus coûteux.

Fine-tuning

Spécialisation

Ré-entraîner le modèle sur vos données métier pour le spécialiser.

Inférence

Génération live

Phase de production : le modèle génère token par token.

Hallucination

⚠ Risque clé

Texte plausible mais faux. Toujours sourcer et vérifier les faits.

LES MODÈLES

DeepSeek — Le game-changer open source

Labo chinois qui a sorti en jan. 2025 un modèle open source (DeepSeek-R1) rivalisant avec GPT-4o à une fraction du coût. A provoqué une onde de choc dans le secteur.

DeepSeek-V3

Chat & Coding

Modèle de base 671B paramètres (MoE). Comparable à GPT-4o. Open weights sur HuggingFace.

DeepSeek-R1

Reasoning

Modèle de raisonnement entraîné par RL pur. Rival de o1. Chaîne de pensée visible.

Coût

L'argument clé

Entraînement : ~6M\$ vs ~100M\$ pour GPT-4.
Inférence : 10-30x moins cher que OpenAI.

MoE

Architecture

Mixture of Experts : seuls ~37B paramètres actifs sur 671B à chaque token. Très efficace.

Token · Contexte · Température

TOKEN — l'unité de traitement

Bon jour le monde ! = 5 tokens

≈ 1 token = ¾ mot en anglais · 1 000 tokens ≈ 750 mots · Impact direct sur le coût

CONTEXT WINDOW

Mémoire de travail du modèle.
Tout ce qu'il voit en même temps.

GPT-4o 128k

Claude 3.5 200k

Gemini 1.5 1M

DeepSeek-V3 128k

TEMPÉRATURE

Créativité vs déterminisme (0.0 → 2.0)

0.0

Déterministe

Code, JSON, SQL

0.7

Équilibré

Usage général

1.2

Créatif

Brainstorm, écriture

2.0

Aléatoire

Expérimental

RAG — Retrieval-Augmented Generation



Document

PDF, Word,
Notion, web...



Chunking

Blocs
~500 tokens



Embedding

Vecteur
numérique



Vector DB

Stockage
Pinecone...



Retrieval

Recherche
similarité



Réponse

LLM +
contexte

Embedding

Représentation vectorielle d'un texte. Deux textes proches sémantiquement ont des vecteurs proches. Base du RAG.

ex. OpenAI text-embedding-3-small

Vector DB

Base de données optimisée pour stocker et retrouver des vecteurs par similarité cosinus.

ex. Pinecone, Chroma, pgvector, Weaviate

Chunking

Stratégie de découpage. Taille et chevauchement (overlap) impactent fortement la qualité de la récupération.

ex. 500 tokens, overlap 50 = bon défaut

Agent IA — Anatomie

Agent = LLM + Boucle de raisonnement + Outils + Mémoire
Objectif donné → planifie des étapes → agit → observe → s'adapte

Boucle ReAct (Reason + Act)



Think



Act



Observe



Adapt



LLM

Le cerveau. Raisonne
sur l'objectif.



Tools

Fonctions appelables :
web, code, API...



Memory

Court terme
(contexte)
long terme (DB).



Planning

Chain-of-Thought,
Tree-of-Thought...

Tool Use — Comment l'IA agit

User → LLM choisit un outil → génère un appel JSON → runtime exécute → LLM reçoit le résultat → réponse finale

Recherche & Web

web_search

browse_url

news_fetch

wikipedia

Code & Fichiers

python_exec

bash

read_file

write_file

APIs & Services

email

calendar

slack

github

Données

sql_query

csv_read


vector_search

scrape

💡 Le LLM génère un appel JSON — il ne « connaît » pas les outils, il les choisit depuis leur description.

MCP — Model Context Protocol

Standard ouvert Anthropic (nov. 2024) — le "USB-C" des agents IA.
N'importe quel LLM ↔ n'importe quel outil via un protocole commun.



💡 Un serveur MCP expose des tools, des ressources et des prompts de façon standardisée.

Skills · System Prompt · Orchestration

Skill / Tool

Capacité encapsulée donnée à un agent :
fonction Python, prompt template, API wrappée.
L'agent choisit quel skill invoquer.

ex. `search_web(query)`, `send_email(to, subject)`

System Prompt

Instructions persistantes avant la conversation.
Définissent rôle, limites, ton. Invisibles pour
l'utilisateur final.

ex. "Tu es un assistant RH. Ne parle pas des salaires."

Orchestrateur

Code ou framework qui coordonne plusieurs
agents et appels LLM. Gère flux de travail,
dépendances et agrégation des résultats.

ex. `LangChain`, `LangGraph`, `CrewAI`, `n8n`, `Make`

Multi-agent

Plusieurs agents spécialisés collaborent. Un
manager délègue à des sous-agents
(researcher, coder, reviewer...).

ex. `A cherche` → `B rédige` → `C valide` → `D publie`

Memory · Grounding · Fine-tuning

4 types de mémoire d'un agent

RAM

In-context

Dans le context window.
Temporaire, effacé à chaque session.

SSD

External DB

Vector DB ou SQL.
Persistant entre les sessions.

Journal

Épisodique

Logs des actions passées.
Apprentissage par l'expérience.

Poids

Sémantique

Connaissances dans les poids du modèle (entraînement).

Grounding

= RAG +
Tools

Ancrer le LLM sur des faits réels via RAG ou tool use. Réduit les hallucinations sans modifier les poids. Rapide à mettre en place.

Fine-tuning

= Entraînement

Ré-entraîner le modèle sur vos données. Modifie les poids. Coûteux mais utile pour style ou vocabulaire très spécifique.

Prompt Engineering

= Instructions

Concevoir des instructions système et des exemples (few-shot) pour guider le comportement sans toucher aux poids du modèle.



D É M O

Chatbot RAG sur vos propres données

Sans RAG

Réponse générique

*« Je n'ai pas accès
à vos documents... »*

⚠ Hallucination possible



Avec RAG ✓

Réponse précise
tirée de VOS documents

« D'après la page 12
de votre doc RH... »

Sourcé & vérifiable


? Sur quels documents vous voudriez ça ?

Stack : LangChain · Chroma · OpenAI Embeddings · text-embedding-3-small



D É M O

Agent researcher — ReAct en action



✨ **Self-healing : l'agent se corrige si une source est inaccessible**

Stack : Claude 3.5 Sonnet · Tool use natif · MCP brave-search

? *Quelle tâche répétitive vous voudriez déléguer ?*



DÉMO — LIVE

Build en live avec Claude Code

> Claude, crée un agent Python avec tool use : input sujet → recherche → rapport structuré.

2 min

On décrit l'objectif en langage naturel

System prompt + tools schema

4 min

Claude génère le code — on analyse ensemble

Tool definitions · ReAct loop · error handling

4 min

On lance l'agent en live

Raisonnement étape par étape visible

5 min

Le public modifie — on itère

Ajouter un tool · changer modèle · ajuster température

💡 Claude Code : un agent coding qui lit votre repo, comprend le contexte et agit en autonomie.

GLOSSAIRE — Les termes clés à retenir

LLM

Modèle de langage massif. Moteur de ChatGPT, Claude, Gemini...

Token

Unité de traitement. $\sim \frac{3}{4}$ mot. Impact sur coût et limite de contexte.

Context

Mémoire de travail du modèle. Tout ce qu'il peut voir = ses tokens.

RAG

Retrieval-Augmented Generation. Brancher le LLM sur vos données.

Agent

LLM + boucle d'action. Objectif → planifie → agit → s'adapte.

Tool Use

LLM qui appelle des fonctions (search, code, API...) via JSON.

MCP

Model Context Protocol. Standard Anthropic pour LLM ↔ outils.

Embedding

Vecteur d'un texte. Proches = sémantiquement similaires.

DeepSeek

LLM open source chinois. Rival de GPT-4o. 10-30x moins cher.

Fine-tuning

Ré-entraîner sur vos données. Modifie les poids du modèle.



Skill

Capacité encapsulée d'un agent : fonction, prompt ou API wrappée.

Orchestration

Coordonner plusieurs agents/LLM calls vers un objectif commun.

CE QU'ON RETIENT



Ressources pour aller plus loin

- Claude docs — docs.anthropic.com
- MCP Registry — github.com/modelcontextprotocol

- LangChain — python.langchain.com
- DeepSeek — api.deepseek.com

Prochain épisode → « On construit ensemble »

Vous apportez un use case — on conçoit l'archi, on code, on déploie.